

Sistema de alertas inteligentes por noticias para carteras de inversión mediante detección de eventos y estimación de impacto con NLP

*Borrador completo para la primera entrega del TFM
Estado de la cuestión, hueco de investigación, propuesta del sistema y plan metodológico*

Máster en Inteligencia Artificial / Ciencia de Datos aplicada a Finanzas

Documento de trabajo orientado a la primera entrega académica

Abril de 2026

Nota de alcance. Este documento presenta una versión continua y académicamente integrada de la primera parte del TFM. Su objetivo principal es justificar el problema, revisar de forma crítica la literatura existente —con especial énfasis en robo-advisors, agentes de inversión y NLP financiero—, identificar un hueco de investigación defendible y proponer una arquitectura técnicamente viable para el desarrollo posterior del prototipo.

Índice

1. Introducción
 2. Problema abordado y motivación
 3. Estado de la cuestión: robo-advisors, sistemas de apoyo a la inversión y agentes basados en LLM
 4. NLP financiero aplicado a noticias y eventos de mercado
 5. Optimización de carteras como marco complementario
 6. Análisis comparativo de trabajos previos
 7. Hueco de investigación detectado
 8. Propuesta del sistema
 9. Metodología prevista
 10. Conclusiones y plan de trabajo
- Referencias bibliográficas

1. Introducción

La inversión financiera contemporánea se desarrolla en un entorno caracterizado por una abundancia sin precedentes de información textual. Noticias corporativas, comunicados regulatorios, presentaciones a inversores, hechos relevantes, informes sectoriales, notas de prensa, transcripciones de resultados y publicaciones macroeconómicas se incorporan continuamente al proceso de formación de expectativas de los agentes. En ese contexto, la dificultad del inversor ya no reside en acceder a información, sino en discriminar cuál de ella es realmente material para sus posiciones y con qué urgencia debe ser procesada.

Esta sobreabundancia informativa coincide, además, con un proceso de automatización creciente del asesoramiento financiero. La literatura sobre robo-advisors ha mostrado que el asesoramiento automatizado se ha consolidado como una línea propia dentro de fintech, especialmente en perfilado de riesgo, asignación de activos y rebalanceo. Cardillo y Chiappini (2024) identifican cuatro grandes corrientes de investigación —clasificación temprana, temas conductuales, rendimiento y modelización algorítmica—, mientras que Zhu, Vigren y Söderberg (2024) sitúan los servicios de asesoramiento financiero impulsados por IA dentro de una transformación más amplia del servicio financiero y de la interacción entre usuario y sistema.

Sin embargo, la literatura también muestra que la automatización del consejo y la lectura de noticias financieras no han convergido todavía, de forma madura, en sistemas centrados en una cartera concreta. Los trabajos sobre robo-advisors se han ocupado principalmente de la asignación eficiente y la experiencia del usuario, mientras que el NLP financiero se ha concentrado en tareas como sentiment analysis, clasificación temática, forecasting o extracción de entidades (Du et al., 2025). Más recientemente, los modelos fundacionales y los agentes basados en LLM han ampliado las posibilidades de análisis, razonamiento y uso de herramientas externas en finanzas, pero todavía presentan retos importantes de evaluación, coste, gobernanza y robustez metodológica (Ding et al., 2024; Dong et al., 2025; Nguyen y Pham, 2026; ESMA, 2025).

Partiendo de este contexto, el presente Trabajo Fin de Máster propone diseñar y evaluar un sistema inteligente de alertas por noticias para carteras de inversión. La idea no es construir un agente de trading autónomo ni sustituir el juicio del inversor, sino desarrollar una capa intermedia de inteligencia informativa capaz de monitorizar fuentes fiables, detectar eventos relevantes para los activos mantenidos en cartera, estimar la posible dirección y severidad del impacto, y emitir alertas explicables con un control razonable del ruido y de los falsos positivos.

El valor diferencial de esta propuesta se apoya en cuatro ejes. En primer lugar, la personalización: la relevancia de una noticia no se tratará como una propiedad absoluta del texto, sino como una relación entre la noticia y la exposición concreta del usuario. En segundo lugar, la representación estructurada del evento: el sistema no se limitará a detectar si una noticia es positiva o negativa, sino que intentará identificar si describe, por ejemplo, resultados empresariales, litigios, regulación, fusiones y adquisiciones, ciberincidentes o problemas operativos. En tercer lugar, la explicabilidad: la alerta deberá indicar qué activo puede verse afectado, qué evento ha sido detectado y por qué la señal se considera suficientemente relevante. En cuarto lugar, la evaluación dual: el sistema deberá ser medible tanto con métricas NLP como con un análisis de utilidad financiera apoyado en estudios de evento.

Desde una perspectiva académica, la relevancia del trabajo reside en que combina varias líneas de investigación activas: robo-advisory, NLP financiero, extracción de eventos, estimación de impacto, evaluación de señales textuales y, de forma complementaria, gestión y revisión de carteras. Desde una

perspectiva aplicada, la propuesta responde a una necesidad real del inversor moderno: reducir la fatiga informativa y priorizar únicamente aquellos eventos con potencial efecto material sobre su cartera.

En consecuencia, este documento se organiza de la siguiente manera. Tras definir el problema y la motivación, se revisa el estado de la cuestión sobre robo-advisors, sistemas de apoyo a la inversión y agentes basados en LLM. A continuación se examina la literatura sobre NLP financiero aplicado a noticias y eventos de mercado, se introduce la optimización de carteras como contexto complementario y se presenta un análisis comparativo de trabajos previos. Finalmente, se formula el hueco de investigación detectado, se describe la propuesta del sistema, se detalla la metodología prevista y se cierra con unas conclusiones y un plan de trabajo para el desarrollo posterior del TFM.

2. Problema abordado y motivación

El problema central que aborda este TFM es la transformación de un flujo masivo y heterogéneo de noticias financieras en señales útiles, personalizadas y operativamente manejables para la supervisión de una cartera de inversión. En la práctica, un inversor puede estar expuesto a decenas o cientos de titulares diarios relacionados con sus empresas, sectores, geografías o riesgos transversales. Filtrar manualmente ese flujo resulta costoso, inconsistente y, en muchos casos, inviable cuando se mantiene una cartera con varias posiciones y distintos horizontes temporales.

El desafío no se reduce a detectar noticias "negativas" o "positivas". En finanzas, la materialidad depende del contexto. Una noticia de tono aparentemente neutro puede ser muy relevante si anticipa un cambio regulatorio, una sanción, una interrupción de suministro o una rebaja de guidance. A la inversa, un titular llamativo puede carecer de consecuencias económicas reales. La revisión de Du et al. (2025) muestra precisamente que el lenguaje financiero se utiliza hoy para muchas tareas distintas — sentimiento, forecasting, cumplimiento normativo, gestión de riesgos o portfolio management—, lo que indica que la utilidad del texto es amplia pero fuertemente dependiente del caso de uso.

Además, la relevancia de una noticia no es universal, sino contextual. Una misma publicación puede ser crítica para un inversor con exposición directa a una compañía determinada y completamente irrelevante para otro. Este hecho diferencia el problema aquí tratado de buena parte de la literatura de sentiment analysis agregada, que evalúa textos por su polaridad general, pero no necesariamente por su relación con una cartera concreta. En este sentido, el usuario no necesita saber solo si el mercado está "más optimista" o "más pesimista", sino si un evento específico puede afectar a sus posiciones y con qué intensidad probable.

Existe también un problema claro de confianza y trazabilidad. La investigación sobre adopción de robo-advisors ha mostrado de manera consistente que variables como la confianza, la ansiedad tecnológica, la expectativa de rendimiento y la preferencia por asesores humanos afectan a la intención de uso (Fatima y Chakraborty, 2024). Complementariamente, Cao, De Zwaan y Wong (2025) subrayan que la confianza en robo-advice se apoya no solo en la tecnología, sino también en la confianza en la firma y en el sistema regulatorio, y que muchos usuarios prefieren modelos híbridos. Esta evidencia es muy relevante para el TFM: una alerta financiera útil no debe ser una caja negra, sino una salida explicable y trazable.

Un riesgo adicional en sistemas de monitorización informativa es la sobrealerta. Un mismo hecho puede aparecer replicado en varios medios, reformulado por agregadores o ampliado en sucesivas publicaciones. Si el sistema no incorpora mecanismos de deduplicación y agrupación semántica, el

usuario puede acabar recibiendo múltiples alertas redundantes sobre un único evento. En la práctica, eso degrada la utilidad del sistema aunque sus modelos de clasificación sean razonablemente buenos.

Por todo ello, la motivación del trabajo es doble. En el plano práctico, se pretende construir una herramienta que ayude a separar señal de ruido para un inversor concreto. En el plano científico, se busca integrar de forma coherente varias piezas de la literatura —relevancia contextual, extracción de eventos, estimación de impacto, explicabilidad y evaluación financiera— en un problema unitario y defendible. Esta combinación convierte el proyecto en una contribución realista y a la vez lo bastante ambiciosa como para resultar relevante dentro de un TFM de perfil técnico.

3. Estado de la cuestión: robo-advisors, sistemas de apoyo a la inversión y agentes basados en LLM

3.1. Robo-advisors tradicionales: foco en asignación, perfilado y automatización del consejo

La literatura reciente coincide en que los robo-advisors constituyen la primera gran ola de automatización del asesoramiento financiero minorista. Su propuesta de valor histórica se ha basado en reducir costes, estandarizar el perfilado de riesgo, automatizar recomendaciones de inversión y facilitar el rebalanceo de cartera. Cardillo y Chiappini (2024), en una revisión sistemática de trabajos publicados entre 2017 y 2022, identifican cuatro clústeres de investigación particularmente estables: clasificación temprana de estos sistemas, temas conductuales, comparación de rendimiento frente a benchmarks y modelización algorítmica.

Este mapa resulta útil porque muestra que la investigación sobre robo-advisors se ha concentrado mucho más en la arquitectura del servicio y en su aceptación por el usuario que en la explotación avanzada de información no estructurada. Desde otra perspectiva, Zhu, Vigren y Söderberg (2024) reinterpretan el robo-advisor como un caso específico de servicio financiero empoderado por IA y subrayan que la literatura sigue dispersa entre finanzas, marketing de servicios, sistemas de información y comportamiento del consumidor. Dicho de otro modo: el robo-advisor no es solo un problema de optimización de carteras, sino también de confianza, interacción y diseño de servicio.

Los trabajos más recientes han sofisticado aún más esta línea. Namyslo, Jung y Sturm (2025) realizan una consolidación sistemática de requisitos de diseño y concluyen que, tras catorce años de investigación, siguen existiendo nociones fragmentadas e incluso inconsistentes sobre lo que constituye un buen diseño de robo-advisory. Su síntesis de seis categorías de requisitos y ocho categorías de recomendaciones apunta a una cuestión importante para este TFM: un sistema de apoyo a la inversión no puede evaluarse solo por la calidad algorítmica de su núcleo, sino también por la forma en que organiza, explica y presenta la información al usuario.

Nourallah, Öhman, Walther y Nguyen (2026), en una revisión de alcance sobre financial robo-advisors, proponen una lectura algo distinta pero complementaria. Para estos autores, la investigación reciente puede resumirse en dos grandes corrientes: una de asset management, centrada en el diseño y funcionamiento técnico de los asesores automatizados, y otra de behavioural finance, centrada en adopción, sesgos y comportamiento. Su diagnóstico refuerza la idea de que todavía existe una separación significativa entre los enfoques de cartera y los enfoques de comportamiento, separación que también aparece cuando se compara la literatura de robo-advisory con la de NLP financiero.

3.2. Adopción, confianza y límites de personalización

Una parte importante de la literatura reciente sobre robo-advisors no se pregunta solo qué hacen estos sistemas, sino por qué los usuarios confían —o no confían— en ellos. Fatima y Chakraborty (2024), analizando el caso de India, muestran que la confianza, la ansiedad, la expectativa de rendimiento y la preferencia por asesores humanos influyen significativamente en la intención de adopción. El resultado es relevante porque el asesoramiento financiero automatizado se desarrolla en un dominio de alto riesgo percibido: incluso cuando la tecnología parece eficiente, la adopción puede frenarse por factores psicológicos y relacionales.

Cao, De Zwaan y Wong (2025) profundizan en esta cuestión desde una lógica de trust transfer theory. Su estudio cualitativo identifica cuatro temas que configuran la confianza en robo-advice: influencia social, comodidad psicológica, salvaguardas y cumplimiento, y capacidad personal. Los autores distinguen además entre confianza en la tecnología, confianza en la firma y confianza en el sistema. Esta triple distinción es especialmente útil para el TFM porque sugiere que un futuro sistema de alertas no debería pensarse solo como un clasificador técnicamente competente, sino como una pieza insertada en una cadena de legitimidad donde importan la fuente, la trazabilidad y la capacidad del usuario para comprender la salida.

Esta lectura se refuerza con trabajos que matizan el efecto de las garantías formales. Tausch, Wischniewski, Yalciner y Neider (2025) estudian el impacto de la certificación y la verificación formal en robo-advisors y concluyen que dichas medidas no incrementan de forma clara la confianza subjetiva del usuario, aunque sí pueden influir en su comportamiento de inversión en determinados contextos experimentales. El hallazgo es importante porque indica que la confianza no se resuelve solo con promesas institucionales; también depende de la experiencia del usuario y de la interpretabilidad práctica de la recomendación.

En conjunto, esta literatura permite extraer una conclusión central para el presente trabajo: los robo-advisors han avanzado en automatización y accesibilidad, pero su personalización suele apoyarse sobre todo en cuestionarios de riesgo, horizonte temporal y asignación de pesos, no en la lectura contextual de eventos textuales que afectan a los activos mantenidos. Esa carencia no invalida su utilidad; simplemente delimita un espacio donde otras capas de inteligencia —como la propuesta en este TFM— pueden resultar complementarias.

3.3. Del asesoramiento automatizado a los agentes de inversión basados en LLM

El salto más reciente dentro del estado del arte se produce con la aparición de agentes financieros basados en grandes modelos de lenguaje. Ding, Li, Wang y Chen (2024) revisan la investigación inicial sobre LLM agents en trading financiero y muestran que la conversación académica se ha desplazado desde la simple explotación de sentimiento textual hacia arquitecturas más complejas, con memoria, reflexión, integración de múltiples fuentes y uso de herramientas externas. El interés de esta línea es evidente: los LLM permiten trabajar con información no estructurada, razonar en lenguaje natural y coordinar subtarefas de investigación financiera que antes aparecían separadas.

El survey de Dong et al. (2025), publicado en Findings of EMNLP, amplía esa imagen con un enfoque más cercano a la práctica institucional. Los autores proponen una taxonomía funcional de cinco dominios —Data Analysis, Investment Research, Trading, Investment Management y Risk Management— y revisan más de treinta benchmarks y veinte modelos representativos. Su conclusión no es triunfalista: aunque el área avanza rápido, persisten problemas de razonamiento numérico,

sensibilidad al prompting, limitada adaptabilidad en tiempo real y falta de alineación con restricciones institucionales y regulatorias.

Esta cautela también aparece en el plano regulatorio y metodológico. El informe de ESMA, elaborado junto al Alan Turing Institute y al Institut Louis Bachelier (ESMA, 2025), no niega el potencial de los LLM en finanzas, pero insiste en una adopción responsable y en la necesidad de prestar atención a gobernanza, privacidad, dependencia de datos, robustez y auditoría. En paralelo, Nguyen y Pham (2026) argumentan que los sistemas multiagente basados en LLM han crecido más rápido que sus estándares de validación y documentan fallos de evaluación particularmente serios —look-ahead bias, survivorship bias, sobreajuste en backtesting, omisión de costes de transacción y ceguera a cambios de régimen— capaces de revertir el signo de los retornos reportados.

Por tanto, el avance hacia agentes de inversión plenamente autónomos no elimina la necesidad de propuestas más acotadas. Al contrario, refuerza la conveniencia de capas intermedias y auditables. Un sistema de alertas por noticias como el que aquí se plantea puede beneficiarse de los avances recientes en NLP y LLM, pero sin asumir el coste metodológico y experimental de validar un agente de trading completo. Esa es precisamente una de las razones por las que este TFM se sitúa deliberadamente entre el robo-advisor clásico y el agente financiero autónomo.

3.4. Síntesis del estado de la cuestión sobre lo que ya existe

La Tabla 1 resume, de forma comparativa, las principales familias de soluciones ya existentes y su relación con la propuesta del TFM.

Familia	Objetivo principal	Entrada típica	Fortalezas	Limitaciones	Relación con este TFM
Robo-advisors clásicos	Perfilado, asignación y rebalanceo	Cuestionarios, precios, restricciones de cartera	Escalabilidad, bajo coste, disciplina de asignación	Poca lectura de texto y baja sensibilidad a eventos informativos	Antecedente directo en personalización financiera, pero no resuelve el filtrado de noticias
Robo-advisory orientado a diseño y confianza	Mejorar adopción, UX y legitimidad	Preferencias de usuario, atributos de interfaz, confianza	Aclara requisitos de adopción y explicabilidad	Menor foco en señal de mercado y procesamiento textual	Aporta criterios de diseño para la interfaz y la trazabilidad de alertas
NLP financiero clásico	Sentimiento, clasificación, forecasting	Noticias, informes, redes sociales, filings	Extrae señal de texto y ofrece baselines robustos	A menudo evalúa tareas aisladas y no una alerta integrada por cartera	Constituye el núcleo técnico de relevancia, eventos e impacto
Agentes LLM financieros	Investigación, razonamiento y decisión asistida o autónoma	Texto, series temporales, herramientas externas	Gran flexibilidad y cobertura de tareas	Coste, evaluación frágil, riesgos de gobernanza y fuga temporal	Representan la frontera del campo, pero exceden el alcance prudente del TFM

Herramientas de optimización de cartera	Asignación de pesos y control de riesgo	Retornos, covarianzas, restricciones, views	Conectan información con decisiones de cartera	No priorizan información textual por sí mismas	Marco complementario para traducir alertas en revisiones tácticas
---	---	---	--	--	---

La tabla pone de manifiesto que la propuesta del TFM no compite frontalmente con una sola de estas familias, sino que integra elementos de varias: adopta la lógica de personalización de los robo-advisors, toma del NLP financiero sus mecanismos de extracción de señal, se mantiene prudente frente a la complejidad de los agentes basados en LLM y se relaciona con la optimización de carteras como un mecanismo posterior de decisión.

4. NLP financiero aplicado a noticias y eventos de mercado

4.1. Del sentiment analysis al modelado semántico del evento

El procesamiento del lenguaje natural en finanzas ha pasado en pocos años de ser un campo relativamente especializado a convertirse en una infraestructura transversal para la extracción de señal desde datos no estructurados. Du, Zhao, Mao, Xing y Cambria (2025) sintetizan esta evolución en diez grandes áreas de aplicación, entre ellas el análisis de sentimiento, el forecasting basado en lenguaje, la gestión de carteras, el cumplimiento normativo, la gestión de riesgos, el question answering y la explicabilidad. Su revisión es importante porque sitúa el texto financiero no como una variable auxiliar, sino como un insumo central de decisión.

Durante mucho tiempo, la puerta de entrada principal al área fue el sentiment analysis. El objetivo consistía en estimar si un texto financiero contenía una polaridad positiva, negativa o neutral, y usar esa señal para explicar o anticipar movimientos de mercado. Araci (2019), con FinBERT, marcó un hito al mostrar que el preentrenamiento y ajuste en dominio financiero mejora de forma clara el rendimiento sobre datasets de sentimiento especializados. Desde entonces, el sentimiento se ha mantenido como baseline casi obligatorio en la literatura aplicada.

Sin embargo, el propio desarrollo del área ha mostrado los límites de esta representación simplificada. No todas las noticias negativas tienen el mismo mecanismo causal ni la misma persistencia económica. Una sanción regulatoria, una rebaja de guidance, un litigio laboral, una interrupción de suministro o un ciberincidente pueden compartir una tonalidad global negativa y, aun así, implicar dinámicas muy distintas para el precio, la volatilidad y el riesgo reputacional. Por ello, el avance natural del campo ha sido desplazarse desde la mera polaridad hacia representaciones más estructuradas del contenido, especialmente extracción de entidades, clasificación temática y detección de eventos.

Esta transición también se observa en los benchmarks. Shah et al. (2022) proponen FLUE como una suite heterogénea de evaluación para lenguaje financiero, precisamente para superar la tendencia a evaluar modelos solo en una tarea aislada. Ahrens, Gorduza y McMahon (2025), con EcoFinBench, van un paso más allá y sostienen que el dominio económico-financiero necesita benchmarks que combinen texto y contexto numérico. Sus resultados son especialmente reveladores porque muestran que los diccionarios financieros tradicionales, aún muy usados como método por defecto, rinden sustancialmente peor que otras alternativas y que los transformers funcionan bien en clasificación textual, pero todavía presentan dificultades cuando la tarea exige combinar lenguaje y metadatos numéricos.

4.2. Datasets, benchmarks y extracción de eventos financieros

Una de las conclusiones más relevantes de la literatura reciente es que el progreso en NLP financiero depende en gran medida de la calidad de los datos y de la disponibilidad de benchmarks especializados. Durante años, gran parte de la investigación se apoyó en conjuntos relativamente pequeños de sentimiento o en datasets creados para una sola tarea. La situación está cambiando, pero no de forma uniforme.

Por un lado, trabajos como FNSPID muestran la importancia de los datasets a gran escala y temporalmente alineados. Dong et al. (2024) presentan un conjunto de datos que integra 29,7 millones de registros de precios y 15,7 millones de noticias financieras alineadas en el tiempo para 4.775 compañías del S&P 500 entre 1999 y 2023. Más allá del tamaño, el interés de FNSPID reside en su orientación multimodal y en que permite conectar texto, tiempo y mercado, algo muy útil para diseñar experimentos cercanos al objetivo de este TFM.

Por otro lado, cuando el interés se desplaza desde sentimiento hacia eventos, el problema se vuelve más exigente. Jacobs et al. (2020) muestran que en noticias económicas y financieras de compañía los disparadores de evento de un solo token suelen ser insuficientes para diferenciar clases finas de eventos, precisamente porque existe un fuerte solapamiento léxico y contextual. Esa observación es clave: en finanzas, la semántica del evento no puede recuperarse solo mediante palabras ancla simples.

En esa misma línea, Jacobs y Hoste (2022) introducen SENTiVENT como un corpus de eventos específicos de compañía en noticias económicas en inglés y subrayan la escasez de recursos manualmente anotados para extracción de eventos en este dominio. Desde la perspectiva del TFM, esta literatura sugiere dos consecuencias metodológicas muy claras: primero, que conviene trabajar con una taxonomía de eventos razonablemente acotada y útil para la inversión; y segundo, que habrá que combinar etiquetado manual con estrategias de baseline robustas, en lugar de asumir que existen datasets perfectamente ajustados al problema propuesto.

4.3. Relevancia contextual: por qué la cartera cambia el problema

Una de las aportaciones conceptuales más importantes del presente trabajo es introducir la cartera como condicionante de la relevancia. En buena parte de la literatura de NLP financiero, la pregunta dominante es si un texto expresa un sentimiento o pertenece a una categoría. En cambio, aquí la pregunta es distinta: ¿afecta esta noticia a los activos que mantiene el usuario? Esa reformulación desplaza el problema desde la clasificación general del texto hacia la relevancia contextualizada por exposición.

Du et al. (2025) ya señalan que el NLP financiero abarca aplicaciones tan diferentes como forecasting, risk management, portfolio management o compliance. Lo que esta amplitud revela es que la utilidad del texto depende del objetivo operativo. En un sistema de alertas para carteras, la relevancia no puede derivarse solo de la intensidad emocional del titular. Requiere identificar entidades, mapearlas a activos o sectores, y valorar también relaciones indirectas: regulación sobre un sector, shocks geográficos, dependencia de materias primas o riesgo en cadena de suministro.

Ahrens et al. (2025) refuerzan esta idea cuando argumentan que el sentido de una afirmación económica o financiera puede depender del contexto numérico y macroeconómico que la acompaña. Trasladado al TFM, esto implica que la relevancia debería modelarse de forma híbrida: reglas y correspondencias directas para menciones explícitas, pero también embeddings o similitud semántica

para capturar dependencias menos obvias. La cartera, por tanto, no es un añadido superficial; es el eje que reordena el problema completo.

4.4. Noticias, reacción del mercado y límites de inferencia

Una cuestión fundamental para el TFM es si las noticias financieras contienen información con capacidad de mover precios o, al menos, de ayudar a identificar eventos materialmente relevantes. La evidencia empírica sugiere una respuesta matizada. Aït-Sahalia, Li y Li (2024) estudian saltos de precios de alta frecuencia y noticias idiosincráticas, sectoriales y macroeconómicas, encontrando que la mayoría de noticias realmente relevantes se incorpora con rapidez al precio. Pero también muestran la cara menos cómoda del problema: la mayor parte de los saltos de precio no puede explicarse mediante una noticia pública identificable.

Esta doble conclusión tiene implicaciones metodológicas directas. Primero, justifica el interés de monitorizar noticias y fuentes primarias, porque sí contienen señal económicamente útil. Segundo, obliga a evitar cualquier planteamiento ingenuamente causal del tipo 'titular negativo = caída de precio'. La relación entre texto y mercado es real, pero incompleta, no determinista y muy dependiente del tipo de evento, del horizonte temporal y del contexto.

Además, la propia metodología de event study ha sido objeto de revisiones críticas recientes. Goldsmith-Pinkham y Lyu (2025) muestran que los estudios de evento financieros tradicionales pueden ofrecer estimaciones inconsistentes cuando el modelo de factores está mal especificado, especialmente en periodos volátiles, en horizontes largos o cuando la ocurrencia del evento se correlaciona con condiciones del mercado. Esta advertencia no invalida el uso de event studies en el TFM, pero sí recomienda prudencia: para la evaluación financiera del sistema será preferible trabajar con ventanas temporales cortas, supuestos explícitos y comparaciones frente a baselines simples, antes que sobre-reivindicar causalidad.

4.5. Implicaciones para este TFM

La literatura revisada sugiere que un sistema de alertas por noticias para carteras no debería apoyarse en una única técnica. El sentimiento puede aportar una señal útil, y modelos de dominio como FinBERT siguen siendo candidatos razonables como feature o baseline. Pero, por sí solo, el sentiment analysis no resuelve la identificación de materialidad. Para ello hacen falta extracción de entidades, clasificación de eventos, modelado de relevancia contextual, manejo de duplicados y una capa explícita de explicación.

En otras palabras, el estado actual del NLP financiero no invalida la propuesta del TFM; la hace más necesaria. Ya existen piezas maduras —embeddings, modelos de dominio, benchmarks, corpora de eventos y grandes datasets temporales—, pero siguen estando dispersas. El reto científico interesante no consiste en inventar una técnica completamente nueva, sino en integrarlas de forma coherente alrededor de una necesidad precisa de inversión: priorizar noticias materialmente relevantes para una cartera concreta.

5. Optimización de carteras como marco complementario

La optimización de carteras no constituye el núcleo del presente TFM, pero sí un marco complementario necesario para situar la utilidad final de las alertas. Detectar eventos informativos relevantes solo cobra pleno sentido cuando se entiende qué tipo de decisión posterior podría desencadenar esa detección: revisar una exposición, reducir un peso, realizar una cobertura o simplemente priorizar una supervisión más atenta del activo afectado.

Zhao et al. (2025), en una revisión sistemática de 224 trabajos publicados entre 2019 y 2024, concluyen que la optimización moderna de carteras sigue siendo un campo fuertemente activo y fragmentado, con extensiones sobre el marco media-varianza, modelos robustos, medidas de riesgo alternativas y enfoques híbridos con aprendizaje automático. Esta diversidad metodológica es útil para el TFM porque confirma que la decisión de cartera rara vez se apoya ya en un único paradigma simple.

En este contexto, el vínculo con el sistema propuesto es claro aunque indirecto. El motor de alertas no decidirá por sí mismo los pesos óptimos, pero sí puede funcionar como una capa previa de vigilancia informativa. De hecho, una parte relevante de la literatura sobre modelos tipo Black-Litterman se basa precisamente en introducir 'views' o visiones externas dentro de la asignación. Trabajos recientes como el de Wu et al. (2025), que extiende Black-Litterman con CVaR y visiones macroeconómicas, muestran que la incorporación de información exógena estructurada sigue siendo una vía fértil de investigación en asignación de activos.

Desde una perspectiva práctica, esta relación puede explorarse sin sobredimensionar el alcance del TFM. Existen librerías maduras como Riskfolio-Lib, cuya documentación oficial la presenta como una herramienta para optimización de carteras en Python construida sobre CVXPY e integrada con estructuras de datos de pandas, con soporte para múltiples funciones objetivo y medidas de riesgo. Esto permite contemplar, en una fase posterior, experimentos sencillos donde una alerta de alta severidad se traduzca en una revisión táctica simulada de la cartera, sin que el trabajo tenga que convertirse en un tratado completo de optimización (Riskfolio-Lib, 2026).

En consecuencia, la optimización de carteras debe entenderse aquí como contexto funcional. No desplaza el foco del TFM; lo enmarca. El sistema propuesto aspira a mejorar la calidad de la información que llega al inversor. La optimización representa uno de los espacios donde, más adelante, esa información podría transformarse en una decisión racional de gestión.

6. Análisis comparativo de trabajos previos

Tras revisar las principales corrientes de literatura, puede sostenerse que los trabajos previos no fallan por falta de calidad, sino por su especialización parcial. Cada subcampo resuelve con eficacia una parte del problema, pero rara vez articula una solución integrada orientada a una cartera concreta. Esta fragmentación es especialmente visible cuando se comparan las finalidades, entradas, salidas y criterios de evaluación de cada familia de trabajos.

Los robo-advisors tradicionales destacan en la automatización del consejo, pero no están diseñados para convertir noticias en alertas individualizadas por posición. Los trabajos de diseño y adopción mejoran la comprensión de la interacción humano-sistema, pero no extraen señal de mercado desde texto. El NLP financiero ofrece herramientas potentes para leer y clasificar información no estructurada, aunque a menudo se queda en tareas parciales. Los agentes LLM, por su parte, prometen una integración muy amplia, pero a costa de mayores exigencias de validación, gobernanza y coste computacional.

Desde el punto de vista del input, también hay una diferencia clara. Los robo-advisors clásicos operan sobre datos estructurados y relativamente estables; el NLP financiero y los agentes LLM explotan textos, resúmenes y documentos no estructurados. Sin embargo, incluso dentro de estas últimas líneas, no siempre se distingue entre noticias relevantes para el mercado en general y noticias relevantes para una cartera dada. Esta distinción es central para el TFM porque permite pasar de un análisis genérico del flujo informativo a una inteligencia situada y personalizada.

En cuanto a la salida, la fragmentación es aún más visible. La mayoría de los estudios en sentimiento producen scores de polaridad; los estudios de clasificación producen etiquetas; los trabajos sobre agents generan recomendaciones, resúmenes o decisiones simuladas. En cambio, el caso de uso del TFM requiere una salida distinta: una alerta priorizada, breve, trazable y suficientemente explicada como para ser útil en la práctica. Esta diferencia de interfaz y de unidad funcional es más importante de lo que parece, porque modifica también cómo debe evaluarse el sistema.

6.1. Criterios de comparación

Para ordenar la comparación, resulta útil analizar los trabajos previos según cinco criterios: finalidad principal, tipo de información utilizada, nivel de personalización, grado de explicabilidad y estrategia de evaluación.

Criterio	Robo-advisors	NLP financiero	Agentes LLM	Implicación para el TFM
Finalidad	Asignación y rebalanceo	Extraer señal de texto	Razonar, investigar o decidir	Generar alertas accionables sin automatizar la decisión final
Entrada	Datos estructurados	Noticias, informes, filings	Texto + herramientas + datos de mercado	Flujo textual fiable + cartera del usuario + metadatos
Personalización	Perfil de riesgo e horizonte	Frecuentemente baja o a nivel de activo	Potencialmente alta, pero costosa	Alta y centrada en exposición real de cartera
Explicabilidad	Moderada, ligada a la recomendación	Variable; a menudo post hoc	Natural en lenguaje, pero no siempre fiel	Explicación operativa en cada alerta
Evaluación	Adopción y rendimiento	F1, accuracy, forecasting	Backtesting y benchmarks heterogéneos	Métricas NLP + utilidad financiera por event study

Vista así, la principal conclusión comparativa es que la propuesta del TFM ocupa una posición intermedia pero no redundante. Toma del robo-advisory la lógica de personalización financiera; toma del NLP financiero los mecanismos para leer texto; recoge de la literatura reciente sobre LLM la idea de integración de módulos, pero renuncia deliberadamente a la autonomía completa para mantener un alcance y una evaluación más controlables.

Esta posición intermedia no es un compromiso débil, sino una estrategia metodológica. Permite formular una contribución original sin prometer capacidades excesivas: no se pretende batir a un gestor profesional ni construir un trader autónomo, sino demostrar que es posible priorizar mejor la información material para una cartera real con ayuda de IA y NLP.

7. Hueco de investigación detectado

El hueco de investigación identificado no consiste en la ausencia total de trabajos sobre inversión automatizada o sobre análisis de noticias financieras. Al contrario, la literatura es abundante en ambos frentes. El problema es que las contribuciones existentes aparecen desalineadas con el caso de uso exacto que aquí interesa: una cartera concreta, un flujo continuo de noticias, una priorización material del evento y una salida final en forma de alerta explicable.

Primero, existe una brecha de integración. Los estudios sobre robo-advisors han avanzado en automatización del consejo; los trabajos de NLP financiero han refinado el análisis de sentimiento, de entidades y de eventos; la literatura de agentes LLM explora arquitecturas más ambiciosas. Pero rara vez estas piezas se ensamblan en un sistema orientado a responder, de manera simultánea, a cuatro preguntas fundamentales para el inversor: si la noticia le afecta, qué evento ha ocurrido, con qué severidad probable podría impactar y por qué merece una alerta.

Segundo, persiste una carencia de personalización por cartera. Aunque los robo-advisors personalizan la asignación y algunos trabajos de NLP se centran en empresas concretas, el uso de la cartera como eje de relevancia sigue siendo comparativamente menos frecuente. El proyecto propuesto introduce precisamente esta dimensión: la noticia deja de ser importante en abstracto y pasa a evaluarse según la exposición real del usuario.

Tercero, el sentimiento sigue ocupando un lugar demasiado central en parte de la literatura aplicada. El problema no es que el sentimiento sea inútil; el problema es tratarlo como representación suficiente del impacto. El hueco, por tanto, no está en construir otro clasificador positivo/negativo, sino en combinar polaridad, evento, materialidad, fuente, corroboración y novedad dentro de un sistema más cercano a la lógica de decisión del inversor.

Cuarto, existe un déficit de explicabilidad operativa. La literatura sobre confianza en robo-advisors y la regulación emergente sobre IA en finanzas apuntan a que las salidas opacas limitan la adopción real. El hueco no es solo técnico, sino también de interfaz: faltan propuestas que conviertan la inferencia del modelo en una alerta corta, comprensible y justificable.

Quinto, la evaluación sigue fragmentada. Muchos trabajos miden F1 o accuracy; otros miden retornos simulados; pocos combinan ambos planos de forma explícita. En este TFM, el hueco se aborda mediante una evaluación dual: por un lado, desempeño lingüístico por módulos; por otro, utilidad financiera aproximada mediante event studies comparados con baselines simples.

8. Propuesta del sistema

Para responder al hueco identificado se propone un sistema inteligente de alertas por noticias orientado a una cartera de inversión declarada por el usuario. La arquitectura se concibe como una cadena modular de transformación de información: cartera del usuario, ingesta de noticias, preprocesado NLP, cálculo de relevancia por cartera, clasificación del evento, estimación de dirección y severidad, motor de alertas y generación final de una salida explicable.

El principio rector del diseño es que el sistema no debe maximizar el número de noticias procesadas ni la complejidad del modelo, sino la utilidad de cada alerta emitida. Una alerta útil es aquella que llega con suficiente rapidez, se refiere a un activo o exposición relevante para el usuario, describe un evento con materialidad plausible, ofrece una estimación prudente del impacto y justifica con claridad por qué se ha disparado.

En la práctica, la propuesta se articula en siete módulos. El primero modela la cartera, normalizando tickers, nombres, sectores y geografías. El segundo adquiere información desde fuentes reputadas y, cuando sea posible, primarias. El tercero limpia y enriquece el texto mediante reconocimiento de entidades y metadatos. El cuarto calcula relevancia por cartera combinando reglas y similitud semántica. El quinto clasifica el tipo de evento. El sexto estima dirección, severidad y confianza. El séptimo fusiona todas las señales en un motor de alertas con anti-spam, deduplicación y explicación final.

Una decisión importante de diseño es la priorización de fuentes. Para el prototipo, resulta razonable apoyarse en mecanismos estables de acceso a fuentes oficiales o semioficiales. La SEC ofrece APIs públicas para acceder a envíos EDGAR y datos XBRL actualizados en tiempo real a través de data.sec.gov y sin necesidad de autenticación (SEC, 2024). La CNMV, por su parte, ofrece canales RSS para notas de prensa, información privilegiada y otra información relevante (CNMV, 2026). Este tipo de fuentes puede combinarse con medios reputados y con la comunicación corporativa publicada en webs de relaciones con inversores.

El sistema no pretende ejecutar operaciones ni reemplazar por completo al analista. Su valor reside en construir una capa intermedia de inteligencia informativa: suficientemente técnica para filtrar y priorizar, pero lo bastante interpretable como para ser usada en entornos reales de apoyo a la decisión.

8.1. Salida esperada de la alerta

Cada alerta generada por el sistema debería contener, como mínimo, los siguientes elementos: activo o activos afectados; tipo de evento; síntesis breve de la noticia; dirección estimada del impacto (alcista, bajista o neutral); severidad estimada; nivel de confianza; fuente o fuentes que respaldan la alerta; y explicación resumida de por qué se considera relevante para la cartera.

Ejemplo de salida:

Posible alerta bajista media para Activo X. Evento detectado: litigio regulatorio. Relevancia alta por mención directa de la compañía en cartera y corroboración en dos fuentes adicionales. Severidad estimada: media. Confianza: 0,81. Motivo: posible incremento de riesgo legal y reputacional con impacto potencial en expectativas de beneficios.

9. Metodología prevista

La metodología se plantea como un desarrollo incremental y modular. El objetivo no es partir de una arquitectura extremadamente compleja, sino construir primero una versión mínima funcional, medible y reproducible, e ir ampliándola después. Este enfoque reduce el riesgo de bloqueo técnico, permite comparar alternativas y favorece la trazabilidad experimental.

En términos generales, el trabajo se organizará en seis fases técnicas: definición del universo de activos y taxonomía de eventos; ingesta y almacenamiento de noticias; preprocesado y enriquecimiento NLP; modelado de relevancia por cartera; clasificación de eventos e impacto; y desarrollo del motor de alertas con posterior evaluación técnica y financiera.

9.1. Fase 1: alcance experimental, activos y taxonomía de eventos

El prototipo trabajará inicialmente con un universo limitado de acciones cotizadas y con una taxonomía de eventos manejable. La selección controlada de activos reduce complejidad y facilita el etiquetado. La taxonomía inicial podrá incluir, entre otras, categorías como resultados empresariales, guidance o profit warning, regulación, litigios, fusiones y adquisiciones, ciberincidentes, incidencias operativas, macroeconomía y cadena de suministro.

La elección de una taxonomía no excesivamente granular responde a lo observado en la literatura de extracción de eventos: clases demasiado finas exigen recursos anotados difíciles de sostener, mientras que categorías demasiado gruesas reducen valor explicativo. El equilibrio deberá buscarse en función del corpus disponible y de la utilidad financiera esperada.

9.2. Fase 2: adquisición de datos y trazabilidad

El pipeline de ingesta se basará en RSS, APIs o páginas de relaciones con inversores con frecuencia de actualización periódica. Se almacenarán título, resumen, fecha, fuente, URL, idioma y, cuando sea viable legalmente, cuerpo del texto. El almacenamiento persistente permitirá reconstruir qué información estaba disponible en cada momento, requisito clave para evitar sesgos temporales.

Se implementará deduplicación en dos niveles: por hash o coincidencia casi exacta y por similitud semántica para agrupar documentos distintos que describen el mismo evento. Este punto es esencial para la utilidad del sistema, ya que evita la multiplicación de alertas por replicación mediática.

9.3. Fase 3: preprocesado NLP y enriquecimiento

El texto se limpiará, normalizará y pasará por detección de idioma, tokenización y reconocimiento de entidades. Se extraerán menciones a compañías, reguladores, países, sectores, productos y otras entidades con valor financiero. Esta capa servirá tanto para el cálculo de relevancia como para la explicación final.

Además del texto, se conservarán metadatos como antigüedad de la noticia, número de fuentes corroborantes, presencia de entidad directa de cartera y posible categoría de origen. La literatura reciente sugiere que estos metadatos son valiosos no solo para la clasificación, sino también para la calibración de confianza y la gestión del spam semántico.

9.4. Fase 4: relevancia por cartera

La relevancia se abordará con un enfoque híbrido. En una primera capa, reglas explícitas capturarán menciones directas a empresas en cartera o a entidades muy próximas. En una segunda capa, embeddings y similitud semántica permitirán detectar relevancia indirecta por sector, geografía o temática. La salida será un score continuo de relevancia contextual.

Esta combinación responde a una lógica práctica: las reglas ofrecen interpretabilidad y bajo coste; las representaciones semánticas permiten mayor cobertura. La cartera dejará así de ser un simple filtro por ticker y pasará a actuar como un objeto semántico y financiero más rico.

9.5. Fase 5: clasificación de eventos e impacto

Para entrenar y evaluar esta capa se construirá un dataset etiquetado manual o semi-manualmente con un subconjunto representativo de noticias. Cada registro incluirá, idealmente, relevancia, tipo de evento, dirección probable del impacto y severidad aproximada. Dado que los recursos de anotación son limitados, se priorizará la consistencia interetiquetador y la calidad de la taxonomía sobre el tamaño bruto del corpus.

En cuanto a modelos, la estrategia recomendada es comenzar con baselines robustos: embeddings más clasificadores tradicionales para evento y dirección, y una clasificación ordinal para severidad. Si la calidad del dato lo permite, estos modelos podrán compararse con alternativas más avanzadas, como transformers de dominio o variantes instruccionales. FinBERT y modelos relacionados pueden incorporarse como baseline o como fuente de features para sentimiento financiero.

También se prestará atención a la calibración. El score de confianza no debe confundirse con la probabilidad bruta del modelo. Métodos de calibración como Platt scaling o isotonic regression permitirán presentar alertas con un grado de seguridad más interpretable.

9.6. Fase 6: motor de alertas y evaluación

La generación de alertas se basará en un score compuesto que combine relevancia, severidad, confianza, credibilidad de la fuente, corroboración, novedad y penalización por redundancia. La lógica de disparo deberá ser deliberadamente conservadora para evitar un exceso de alertas de baja utilidad.

La evaluación se realizará en dos niveles. En el plano NLP se utilizarán precisión, recall, F1, matrices de confusión y medidas de calibración. En el plano financiero se realizará un análisis de evento en ventanas temporales cortas, comparando las alertas emitidas con baselines más simples —por ejemplo, alertado por palabras clave, por sentimiento genérico o por mera mención de una compañía—. La advertencia metodológica de Goldsmith-Pinkham y Lyu (2025) sobre los event studies justifica adoptar un planteamiento prudente, transparente y comparativo.

En conjunto, la metodología pretende equilibrar ambición y viabilidad. El proyecto es técnicamente exigente, pero se acota mediante una arquitectura modular, un conjunto limitado de activos y una evaluación incremental que permita defender resultados parciales sólidos.

10. Conclusiones y plan de trabajo

La revisión bibliográfica y el análisis comparativo permiten concluir que el problema propuesto para el TFM es actual, relevante y metodológicamente defendible. La automatización del asesoramiento financiero ha avanzado de forma notable, pero la literatura sigue mostrando una separación entre sistemas centrados en cartera, técnicas de NLP financiero y arquitecturas más recientes basadas en LLM. Existe, por tanto, un espacio legítimo para propuestas que integren estas piezas de forma orientada a un caso de uso concreto y evaluable.

El trabajo propuesto no pretende competir con los sistemas más ambiciosos del mercado ni con la literatura más especulativa sobre agentes autónomos de trading. Su aportación esperada es más específica y, precisamente por ello, más defendible: diseñar una capa de inteligencia informativa personalizada que monitorice noticias, detecte eventos relevantes para una cartera, estime impacto y emita alertas explicables con un control razonable del ruido y de la redundancia.

De aquí a la siguiente fase del TFM, el plan de trabajo puede organizarse en cuatro bloques prácticos. El primero consiste en consolidar la revisión bibliográfica y cerrar la taxonomía de eventos. El segundo, en construir el pipeline de ingesta y almacenamiento. El tercero, en preparar el corpus etiquetado y desarrollar los primeros baselines de relevancia, evento e impacto. El cuarto, en integrar el motor de alertas y ejecutar la evaluación dual. Si el tiempo y los datos lo permiten, podrá añadirse una exploración complementaria sobre cómo usar las alertas como señales para una revisión táctica de la cartera.

En definitiva, la idea central del TFM queda bien situada frente a la literatura existente: no sustituir al inversor, sino mejorar de forma medible la calidad, oportunidad y explicabilidad de la información que recibe. Ese es, a la vez, su principal valor práctico y su principal justificación académica.

Referencias bibliográficas

- Araci, D. (2019). FinBERT: Financial Sentiment Analysis with Pre-trained Language Models. arXiv. <https://doi.org/10.48550/arXiv.1908.10063>
- Ahrens, M., Gorduza, D., y McMahon, M. (2025). EcoFinBench — a natural language processing benchmark for economics and finance. Bank of England Staff Working Paper No. 1,163.

- Aït-Sahalia, Y., Li, C. X., y Li, C. (2024). So Many Jumps, So Few News. NBER Working Paper No. 32746. <https://doi.org/10.3386/w32746>
- Cao, X., De Zwaan, L., y Wong, V. (2025). Building trust in robo-advisory: technology, firm-specific and system trust. *Qualitative Research in Financial Markets*, 18(2), 408–428. <https://doi.org/10.1108/QRFM-02-2024-0033>
- Cardillo, G., y Chiappini, H. (2024). Robo-advisors: A systematic literature review. *Finance Research Letters*, 62, 105119. <https://doi.org/10.1016/j.frl.2024.105119>
- CNMV. (2026). RSS Channel / Feed. Comisión Nacional del Mercado de Valores.
- Ding, H., Li, Y., Wang, J., y Chen, H. (2024). Large Language Model Agent in Financial Trading: A Survey. *arXiv*. <https://doi.org/10.48550/arXiv.2408.06361>
- Dong, Y., Wu, F., Zhang, K., Dai, Y., Zhang, S., Ye, W., Chen, S., y Cheng, Z.-Q. (2025). Large Language Model Agents in Finance: A Survey Bridging Research, Practice, and Real-World Deployment. *Findings of the Association for Computational Linguistics: EMNLP 2025*, 17889–17907.
- Dong, Z., Yu, X., Xu, W., et al. (2024). FNSPID: A Comprehensive Financial News Dataset in Time Series. *arXiv*. <https://doi.org/10.48550/arXiv.2402.06698>
- Du, K., Zhao, Y., Mao, R., Xing, F., y Cambria, E. (2025). Natural language processing in finance: A survey. *Information Fusion*, 115, 102755. <https://doi.org/10.1016/j.inffus.2024.102755>
- ESMA. (2025). Working Paper on Leveraging Large Language Models in Finance: Pathways to Responsible Adoption. European Securities and Markets Authority.
- Fatima, S., y Chakraborty, M. (2024). Adoption of artificial intelligence in financial services: The case of robo-advisors in India. *IIMB Management Review*, 36(2), 113–125. <https://doi.org/10.1016/j.iimb.2024.04.002>
- Goldsmith-Pinkham, P., y Lyu, T. (2025). Causal Inference in Financial Event Studies. Working paper, Yale University & NBER.
- Jacobs, G., Hoste, V., Lefever, E., y Van Hee, C. (2020). Extracting Fine-Grained Economic Events from Business News. *Proceedings of the 1st Joint Workshop on Financial Narrative Processing and MultiLing Financial Summarisation*.
- Jacobs, G., y Hoste, V. (2022). SENTiVENT: enabling supervised information extraction of company-specific events in economic and financial news. *Language Resources and Evaluation*, 56, 1227–1260. <https://doi.org/10.1007/s10579-021-09562-4>
- Namyslo, N. M., Jung, D., y Sturm, T. (2025). The state of robo-advisory design: A systematic consolidation of design requirements and recommendations. *Electronic Markets*, 35, 20. <https://doi.org/10.1007/s12525-025-00762-2>
- Nguyen, P., y Pham, T. (2026). Toward Reliable Evaluation of LLM-Based Financial Multi-Agent Systems: Taxonomy, Coordination Primacy, and Cost Awareness. *arXiv*. <https://doi.org/10.48550/arXiv.2603.27539>
- Nourallah, M., Öhman, P., Walther, T., y Nguyen, D. K. (2026). Financial robo-advisors: A scoping review and future research directions. *Journal of Behavioral and Experimental Finance*, 49, 101158. <https://doi.org/10.1016/j.jbef.2026.101158>
- Riskfolio-Lib. (2026). Documentation, version 7.2. <https://riskfolio-lib.readthedocs.io/>
- SEC. (2024). EDGAR Application Programming Interfaces (APIs). U.S. Securities and Exchange Commission.

- Shah, R. S., Chawla, K., Eidnani, D., Shah, A., Du, W., Chava, S., Raman, N., Smiley, C., Chen, J., y Yang, D. (2022). When FLUE Meets FLANG: Benchmarks and Large Pre-trained Language Model for Financial Domain. *Proceedings of EMNLP 2022*. <https://doi.org/10.18653/v1/2022.emnlp-main.148>
- Tausch, A., Wischnewski, M., Yalciner, M., y Neider, D. (2025). Formal verification for robo-advisors: Irrelevant for subjective end-user trust, yet decisive for investment behavior? *arXiv*. <https://doi.org/10.48550/arXiv.2509.08540>
- Wu, Y., Sun, J., y colaboradores. (2025). A CVaR-Based Black-Litterman Model with Macroeconomic Cycle Views for Optimal Asset Allocation. *Mathematics*, 13(24), 4034.
- Zhao, Y., y colaboradores. (2025). How to optimize modern portfolio theory? A systematic review and research agenda. *Expert Systems with Applications*, 268, 125780. <https://doi.org/10.1016/j.eswa.2024.125780>
- Zhu, H., Vigren, O., y Söderberg, I.-L. (2024). Implementing artificial intelligence empowered financial advisory services: A literature review and critical research agenda. *Journal of Business Research*, 174, 114494. <https://doi.org/10.1016/j.jbusres.2023.114494>